

Exercícios Redes Neurais



Aprendizado de Máquina

Prof. Me. Otávio Parraga

Dissertativas

1. Toda rede neural passa por três processos durante o treinamento. A passagem forward, a função de custo e a passagem backward. Explique cada um desses processos.
2. Explique a importância das funções de ativação em redes neurais. Por que não podemos usar apenas funções lineares?
3. Existe alguma solução analítica/equação normal para o treinamento de redes neurais? Justifique sua resposta considerando o formato da função de custo.
4. Explique quais são os dois passos da passagem backward em redes neurais.
5. Explique o que é Data Augmentation e como ele pode ajudar a melhorar o desempenho de uma rede neural.

Objetivas

1. Qual das seguintes funções de ativação é mais adequada para a última camada em um problema de classificação binária?
 - a) ReLU
 - b) Sigmoid
 - c) Tanh
 - d) Softmax
 - e) Sinal
2. Em uma rede neural, qual é o principal objetivo da função de custo?
 - a) Ajustar os pesos da rede
 - b) Medir a diferença entre as previsões da rede e os valores reais
 - c) Normalizar os dados de entrada
 - d) Aumentar a complexidade do modelo
 - e) Reduzir o número de camadas na rede
3. Qual das técnicas abaixo não é uma forma de regularização em redes neurais?
 - a) Dropout

- b) Early Stopping
- c) Data Augmentation
- d) Batch Normalization
- e) Aumento do número de neurônios

4. Por que não podemos usar a função sinal em uma MLP (Perceptron Multicamadas)?

- a) Porque é computacionalmente muito cara
- b) Porque não é diferenciável, o que impede o uso do algoritmo de backpropagation
- c) Porque não é adequada para problemas de regressão
- d) Porque causa overfitting
- e) Porque não funciona com grandes conjuntos de dados

5. Sobre redes neurais, assinale a alternativa correta:

- a) Redes neurais profundas sempre evitam o overfitting
- b) A função ReLU é sempre melhor que a função Sigmoid
- c) O algoritmo de backpropagation é usado para ajustar os pesos da rede com base no erro da previsão
- d) Redes neurais não podem ser usadas para problemas de regressão
- e) A normalização dos dados não afeta o desempenho da rede neural

6. Dadas as sentenças abaixo, assinale se é verdadeira ou falsa e corrija quando for falsa:

- () A função de ativação ReLU é linear para valores positivos e zero para valores negativos.
- () O overfitting ocorre quando a rede neural generaliza bem para dados não vistos.
- () A técnica de Dropout ajuda a prevenir o overfitting ao desativar aleatoriamente neurônios durante o treinamento.
- () A função de custo MSE é mais adequada para problemas de classificação do que para regressão.
- () O algoritmo de backpropagation utiliza o gradiente descendente para atualizar os pesos da rede com base no erro da previsão.
- () Redes Neurais são algoritmos muito recentes e começaram a ser desenvolvidas apenas após 2010.
- () A taxa de aprendizado controla a velocidade com que os pesos da rede são atualizados durante o treinamento.
- () A normalização dos dados de entrada pode melhorar a convergência do treinamento da rede neural.
- () A função ativação ReLU não pode ser usada, uma vez que ela é uma função linear.

7. Suponha o seguinte cenário, um colega está treinando uma rede neural para classificação de imagens, mas está enfrentando problemas de overfitting. Qual das abordagens a seguir não serve para contornar o problema?

- a) Aumentar o tamanho do conjunto de dados de treinamento usando Data Augmentation.
- b) Implementar Dropout durante o treinamento da rede.
- c) Reduzir a complexidade do modelo, diminuindo o número de camadas ou neurônios.
- d) Aumentar o número de épocas de treinamento.
- e) Utilizar técnicas de regularização, como L2 regularization.

Cálculos

1. Considere uma rede neural simples, com uma camada oculta e uma camada de saída. A camada de entrada possui um neurônio e a de saída também. A função de ativação das duas camadas é uma função sigmoide. Dadas as seguintes entradas e pesos, calcule a saída da rede neural e faça um passo de otimização dos pesos. Considere uma taxa de aprendizado de 0,1.

- Entrada: 0,7
- Peso da camada oculta: 0,5
- Peso da camada de saída: 0,9
- Valor alvo (target): 1,0

Passo 1: Calcule a saída da camada oculta usando a função sigmoide.

Passo 2: Calcule a saída final da rede usando a função sigmoide.

Passo 3: Calcule o erro usando a função de custo MSE (Mean Squared Error).

Passo 4: Faça um passo de otimização dos pesos usando o gradiente descendente.

Mostre todos os cálculos intermediários.

2. Considere uma rede neural simples, com uma camada oculta e uma camada de saída. A camada de entrada possui um neurônio e a de saída também. A função de ativação da primeira camada é uma ReLU e a da segunda camada é uma sigmoide. Dadas as seguintes entradas e pesos, calcule a saída da rede neural e faça um passo de otimização dos pesos. Considere uma taxa de aprendizado de 0,1.

- Entrada: 0,6
- Peso da camada oculta: 0,4
- Peso da camada de saída: 0,8
- Valor alvo (target): 0,0

Passo 1: Calcule a saída da camada oculta usando a função ReLU.

Passo 2: Calcule a saída final da rede usando a função sigmoide.

Passo 3: Calcule o erro usando a função de custo MSE (Mean Squared Error).

Passo 4: Faça um passo de otimização dos pesos usando o gradiente descendente.

Mostre todos os cálculos intermediários.

3. Considere uma rede neural simples com uma camada oculta. A camada de entrada possui 3 neurônios, a camada oculta possui 2 neurônios e a camada de saída possui 1 neurônio. As funções de ativação são ReLU para a camada oculta e Sigmoid para a camada de saída. Dadas as seguintes entradas e pesos, calcule a saída da rede neural.

- Entradas: [0.5, 0.2, 0.1]
- Pesos da camada oculta:
 - Neurônio 1: [0.4, 0.6, 0.8]
 - Neurônio 2: [0.3, 0.7, 0.5]
- Pesos da camada de saída:
 - Neurônio de saída: [0.9, 0.1]

Passo 1: Calcule a saída da camada oculta usando a função ReLU.

Passo 2: Calcule a saída final da rede usando a função Sigmoid.

Mostre todos os cálculos intermediários.